

Relatório Olimpíadas 2000 - 2016

Consultores Responsáveis:

Felipe Bretas

Requerente:

João Neves

Brasília, 6 de novembro de 2024.



Sumário

	Página
1 Introdução	4
2 Referencial Teórico	5
2.1 Frequência Relativa	5
2.2 Média	5
2.3 Mediana	5
2.4 Variância	6
2.4.1 Variância Populacional	6
2.4.2 Variância Amostral	7
2.5 Desvio Padrão	7
2.5.1 Desvio Padrão Populacional	7
2.5.2 Desvio Padrão Amostral	8
2.6 Boxplot	8
2.7 Gráfico de Dispersão	9
2.8 Tipos de Variáveis	9
2.8.1 Qualitativas	9
2.8.2 Quantitativas	10
2.9 Coeficiente de Correlação de Spearman	10
3 Análises	11
3.1 Relação de medalhas femininas por país	11
3.2 Relação do IMC por esporte	12
3.3 Relação entre medalhistas e o tipo de medalha	13
3.4 Relação entre peso e altura	15
4 Conclusões	17

```

\begin{quadro}[H]
\setlength{\tabcolsep}{9pt}
\renewcommand{\arraystretch}{1.20}
\caption{Medidas resumo da(o) [nome da variável]}
\centering
\begin{adjustbox}{max width=\textwidth}
\begin{tabular}{|l|}
S[table-format = 0.2]
|}
\hline
\textbf{Estatística} & \textbf{Valor} \\
\hline
Média & 1,78

```

```

Desvio Padrão & 0,12 \\
Variância & 0,01 \\
Mínimo & 1,37 \\
1º Quartil & 1,7 \\
Mediana & 1,78 \\
3º Quartil & 1,86 \\
Máximo & 2,19 \\
\hline
\end{tabular}
\label{quad:quadro_resumo1}
\end{adjustbox}
\end{quadro}

\begin{quadro}[H]
\setlength{\tabcolsep}{9pt}
\renewcommand{\arraystretch}{1.20}
\caption{Medidas resumo da(o) [nome da variável]}
\centering
\begin{adjustbox}{max width=\textwidth}
\begin{tabular}{|l|}
S[table-format = 2.2]
|}
\hline
\textbf{Estatística} & \textbf{Valor} \\
\hline
Média & 74,14 \\
Desvio Padrão & 16,25 \\
Variância & 264,11 \\
Mínimo & 28 \\
1º Quartil & 63 \\
Mediana & 72 \\
3º Quartil & 84 \\
Máximo & 175 \\
\hline
\end{tabular}
\label{quad:quadro_resumo1}
\end{adjustbox}
\end{quadro}

```

1 Introdução

Este relatório tem como objetivo um estudo mais aprofundado, por meio de análises descritivas, por meio de diversos gráficos, tabelas e quadros, sendo também analisadas suas correlações, sobre a performance de atletas nas Olimpíadas dos anos 2000 até 2016, a fim de entender melhor o desempenho e possíveis relações desses atletas de elite da academia de alta performance “House of Excellence”.

O banco de dados foi coletado pelo próprio cliente, possuindo uma boa amostra para fins de estudo contendo um total de 9 variáveis para a confecção da análise, possuindo variáveis tanto qualitativas quanto quantitativas.

O software utilizado para a realização desta análise é o R, sendo este um software livre em sua versão 4.3.3.

2 Referencial Teórico

2.1 Frequência Relativa

A frequência relativa é utilizada para a comparação entre classes de uma variável categórica com c categorias, ou para comparar uma mesma categoria em diferentes estudos.

A frequência relativa da categoria j é dada por:

$$f_j = \frac{n_j}{n}$$

Com:

- $j = 1, \dots, c$
- n_j = número de observações da categoria j
- n = número total de observações

Geralmente, a frequência relativa é utilizada em porcentagem, dada por:

$$100 \times f_j$$

2.2 Média

A média é a soma das observações dividida pelo número total delas, dada pela fórmula:

$$\bar{X} = \frac{\sum_{i=1}^n X_i}{n}$$

Com:

- $i = 1, 2, \dots, n$
- n = número total de observações

2.3 Mediana

Sejam as n observações de um conjunto de dados $X = X_{(1)}, X_{(2)}, \dots, X_{(n)}$ de determinada variável ordenadas de forma crescente. A mediana do conjunto de dados X é o valor que deixa metade das observações abaixo dela e metade dos dados acima.

Com isso, pode-se calcular a mediana da seguinte forma:

$$med(X) = \begin{cases} X_{\frac{n+1}{2}}, & \text{para } n \text{ ímpar} \\ \frac{X_{\frac{n}{2}} + X_{\frac{n}{2}+1}}{2}, & \text{para } n \text{ par} \end{cases}$$

Quartis

Os quartis são separatrizes que dividem o conjunto de dados em quatro partes iguais. O primeiro quartil (ou inferior) delimita os 25% menores valores, o segundo representa a mediana, e o terceiro delimita os 25% maiores valores. Inicialmente deve-se calcular a posição do quartil:

- Posição do primeiro quartil P_1 :

$$P_1 = \frac{n + 1}{4}$$

- Posição da mediana (segundo quartil) P_2 :

$$P_2 = \frac{n + 1}{2}$$

- Posição do terceiro quartil P_3 :

$$P_3 = \frac{3 \times (n + 1)}{4}$$

Com n sendo o tamanho da amostra. Dessa forma, $X_{(P_i)}$ é o valor do i -ésimo quartil, onde $X_{(j)}$ representa a j -ésima observação dos dados ordenados.

Se o cálculo da posição resultar em uma fração, deve-se fazer a média entre o valor que está na posição do inteiro anterior e do seguinte ao da posição.

2.4 Variância

A variância é uma medida que avalia o quanto os dados estão dispersos em relação à média, em uma escala ao quadrado da escala dos dados.

2.4.1 Variância Populacional

Para uma população, a variância é dada por:

$$\sigma^2 = \frac{\sum_{i=1}^N (X_i - \mu)^2}{N}$$

Com:

- X_i = i -ésima observação da população
- μ = média populacional
- N = tamanho da população

2.4.2 Variância Amostral

Para uma amostra, a variância é dada por:

$$S^2 = \frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}$$

Com:

- X_i = i -ésima observação da amostra
- \bar{X} = média amostral
- n = tamanho da amostra

2.5 Desvio Padrão

O desvio padrão é a raiz quadrada da variância. Ele avalia o quanto os dados estão dispersos em relação à média.

2.5.1 Desvio Padrão Populacional

Para uma população, o desvio padrão é dado por:

$$\sigma = \sqrt{\frac{\sum_{i=1}^N (X_i - \mu)^2}{N}}$$

Com:

- X_i = i -ésima observação da população
- μ = média populacional
- N = tamanho da população

2.5.2 Desvio Padrão Amostral

Para uma amostra, o desvio padrão é dado por:

$$S = \sqrt{\frac{\sum_{i=1}^n (X_i - \bar{X})^2}{n - 1}}$$


Com:

- X_i = i-ésima observação da amostra
- \bar{X} = média amostral
- n = tamanho da amostra

2.6 Boxplot

O boxplot é uma representação gráfica na qual se pode perceber de forma mais clara como os dados estão distribuídos. A figura abaixo ilustra um exemplo de boxplot.

Figura 1: Exemplo de boxplot




A porção inferior do retângulo diz respeito ao primeiro quartil, enquanto a superior indica o terceiro quartil. Já o traço no interior do retângulo representa a mediana do conjunto de dados, ou seja, o valor em que o conjunto de dados é dividido em dois subconjuntos de mesmo tamanho. A média é representada pelo losango branco e os

pontos são *outliers*. Os *outliers* são valores discrepantes da série de dados, ou seja, valores que não demonstram a realidade de um conjunto de dados.

2.7 Gráfico de Dispersão

O gráfico de dispersão é uma representação gráfica utilizada para ilustrar o comportamento conjunto de duas variáveis quantitativas. A figura abaixo ilustra um exemplo de gráfico de dispersão, onde cada ponto representa uma observação do banco de dados.

Figura 2: Exemplo de Gráfico de Dispersão



2.8 Tipos de Variáveis

2.8.1 Qualitativas

As variáveis qualitativas são as variáveis não numéricas, que representam categorias ou características da população. Estas subdividem-se em:

- **Nominais:** quando não existe uma ordem entre as categorias da variável (exemplos: sexo, cor dos olhos, fumante ou não, etc)
- **Ordinais:** quando existe uma ordem entre as categorias da variável (exemplos: nível de escolaridade, mês, estágio de doença, etc)

2.8.2 Quantitativas

As variáveis quantitativas são as variáveis numéricas, que representam características numéricas da população, ou seja, quantidades. Estas subdividem-se em:

- **Discretas:** quando os possíveis valores são enumeráveis (exemplos: número de filhos, número de cigarros fumados, etc)
- **Contínuas:** quando os possíveis valores são resultado de medições (exemplos: massa, altura, tempo, etc)

2.9 Coeficiente de Correlação de Spearman

O coeficiente de correlação de Spearman é uma medida não paramétrica que verifica, através de postos de variáveis quantitativas ou qualitativas ordinais, o grau de relação linear entre duas variáveis. Este coeficiente varia entre os valores -1 e 1. O valor zero significa que não há relação linear entre as variáveis. Quando o valor do coeficiente ρ é negativo, diz-se existir uma relação de grandeza inversamente proporcional entre as variáveis. Analogamente, quando ρ é positivo, diz-se que as duas variáveis são diretamente proporcionais.

O coeficiente é calculado da seguinte maneira:

$$\rho_{Spearman} = \frac{\sum_{i=1}^n \left[\left(R(x_i) - \frac{n+1}{2} \right) \left(R(y_i) - \frac{n+1}{2} \right) \right]}{\sqrt{\sum_{i=1}^n (R(x_i)^2) - n \left(\frac{n+1}{2} \right)^2} \times \sqrt{\sum_{i=1}^n (R(y_i)^2) - n \left(\frac{n+1}{2} \right)^2}}$$

Onde:

- x_i = i-ésimo valor da variável X
- y_i = i-ésimo valor da variável Y
- $R(x_i)$ = posto relativo à observação i de X
- $R(y_i)$ = posto relativo à observação i de Y
- n = número total de observações na amostra

3 Análises


3.1 Relação de medalhas femininas por país

Desde o século XX, as mulheres vêm ganhando espaço em diversas áreas de atuação que antes eram consideradas exclusivamente dos homens. Uma conquista muito grande do público feminino foi o ingresso nas Olimpíadas e, com a virada do século, o investimento se tornou ainda maior.

Para a confecção desta análise, foram utilizadas as variáveis: “Sexo” (qualitativa nominal), “Medalha” (qualitativa ordinal) e “País” (qualitativa nominal) que significam respectivamente, o gênero dos atletas participantes; se o atleta ganhou medalha e seu tipo, sendo estes ouro, prata ou bronze; e o país que o atleta representou.

Este estudo tem como finalidade compreender quais foram os países que tiveram o maior número de medalhistas femininas nas Olimpíadas de 2000 até 2016, analisando os 5 que se saíram mais vencedores nessas edições, como é mostrado na figura a seguir:

Figura 3: Gráfico de colunas do total de medalhas femininas por país



Como pode ser observado pelo **Figura 3**, os Estados Unidos possui o maior número de medalhas quanto se trata de atletas femininas, com um total de 146, representando 16,1% no total de medalhistas mulheres das Olimpíadas de 2000 até 2016, havendo uma diferença de 7,2% para o segundo colocado Rússia.

Algo que também pode ser observado é a grande variedade de continentes presentes dentro do top 5 medalhistas femininas, sendo estes: América, Europa, Ásia e

Oceania, mostrando que existe uma grande variedade muito grande entre as atletas ganhadoras.

Essa diferença pode ser explicada pelo alto investimento que os Estados Unidos faz em suas atletas desde a infância, as incentivando a praticarem esportes de alto rendimento em toda sua fase de educação.

Algo que também deve ser observado é a frequência relativa acumulada entre esses 5 países mais vencedores os quais equivalem à 46,7% do total de medalhas ganhas por atletas femininas em todas as Olimpíadas em análise.


3.2 Relação do IMC por esporte

O Índice de Massa Corporal, mais conhecido como IMC, é uma medida internacional adotada para verificar se uma pessoa estaria numa certa faixa de “peso ideal”. Esse índice varia por diversos aspectos e, entre um deles, está se a pessoa pratica ou não algum esporte.

Para esta análise, foram utilizadas as variáveis: “Altura (cm)” (quantitativa contínua), “Peso (kg)” (quantitativa contínua) e “Esporte” (qualitativa nominal), significando respectivamente: altura de cada atleta participante em centímetros; peso de cada atleta em quilogramas; esporte que o competidor participou.

A fim de tentar compreender melhor essa relação, foi feita uma análise descritiva entre alguns dos esportes olímpicos e seus atletas, demonstrado pela figura e gráfico abaixo:

Figura 4: Boxplot do IMC por esporte



Quadro 1: Medidas resumo do Índice de Massa Corporal

Estatística	Atletismo	Badminton	Futebol	Ginástica	Judô
Média	22,30	22,21	22,51	20,68	25,70
Desvio Padrão	3,86	1,50	1,73	2,38	5,12
Variância	14,92	2,26	2,99	5,67	26,24
Mínimo	15,82	18,94	16,73	15,16	18,52
1º Quartil	20,03	21,22	21,34	18,61	22,06
Mediana	21,45	22,28	22,49	21,09	24,68
3º Quartil	23,67	23,22	23,71	22,48	27,70
Máximo	44,38	26,73	29,07	26,45	56,50

Como pode ser observado pelo **Figura 4**, os atletas de ginástica são os que apresentam menor mediana em relação aos outros esportes. Uma explicação para esse motivo se dá pelo fato dos atletas de ginástica precisarem muito de sua mobilidade e agilidade para executarem suas acrobacias, necessitando de uma menor taxa de IMC para facilitar os movimentos.

Algo que também vale a pena ser observado é o grande número de outliers nos competidores de atletismo, evidenciando a diversidade possível para os atletas entrarem em suas competições. Porém, mesmo com essa grande presença desse outliers, ainda apresentam a segunda menor mediana de IMC por atletas por esporte.

Como pode ser observado pelo quadro acima, a média entre os atletas de atletismo, badminton e futebol são bastante parecidas, todas em um pouco acima de 22. Algo que também vale a pena ser ressaltado é a grande variabilidade presente entre os atletas de atletismo e principalmente os de judô, os quais possuem um desvio padrão respectivamente de 3,86 e 5,12. Isso pode ser explicado pela grande diversidade de modalidades que englobam o atletismo e a diferença entre categorias presentes no judô.

3.3 Relação entre medalhistas e o tipo de medalha

O sonho de cada atleta que adentra uma Olimpíadas é conquistar alguma medalha para seu país. Para isso é necessário anos de dedicação, treinos intensos e muito talento para ter uma chance de conquistar a tão sonhada medalha. Graças à combinação de todos esses fatores, existem competidores que conseguem atingir um maior sucesso que os demais, adquirindo um grande total de medalhas ao longo de vários anos.

A fim de tentar entender melhor quais são os atletas que possuem mais medalhas entre as Olimpíadas de 2000 até 2016, foi feita uma análise descritiva utilizando as variáveis: “Nomes” (qualitativa nominal), “Medalha” (qualitativa ordinal), significando

respectivamente: o nome dos atletas participantes; medalha conquistada e seu tipo, sendo estes, ouro, prata e bronze. Além dessas variáveis, foi utilizado a figura e a tabela a seguir:

Figura 5: Gráfico de colunas de medalhas por atleta

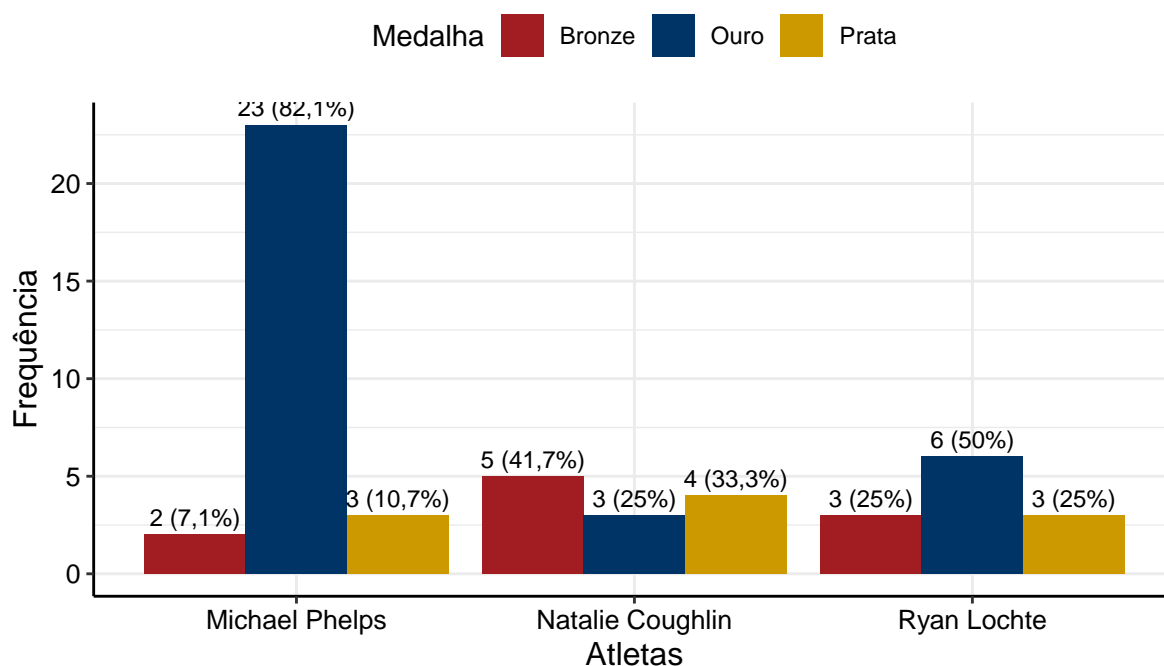


Tabela 1: Frequências da variável Medalha

Medalha	Frequência	Porcentagem
Ouro	32	61,54%
Prata	10	19,23%
Bronze	10	19,23%
Total	52	100,00%

Como pode ser observado pela **Figura 5**, o atleta Michael Phelps é quem detem o maior número de medalhas olímpicas entre 2000 até 2016, totalizando 28 medalhas, dentre elas 23 sendo de ouro, representando 82,1%. Para fechar o top 3 tem a atleta Natalie Coughlin e Ryan Lochte, ambos empatados no total de medalhas com 12 cada.

Nesta análise também foi estudado se há ou não uma associação entre o tipo da medalha e o atleta que a conquistou e para isso, foi utilizado o Coeficiente de Contingência Modificado, $C^*=0,2719$, evidenciando uma associação moderada.

Graças ao Coeficiente estudado, podemos dizer que uma certa relação entre o tipo da medalha conquistada e atleta que a conquistou, mostrando que o talento individual, além de anos de treino e esforço, pode ser um fator determinante quanto o assunto se trata de uma conquista grande.


Como mostrado na tabela acima, algo que também vale a pena ser ressaltado é o número de medalhas de ouro conquistadas pelos 3 maiores ganhadores das Olimpíadas de 2000 até 2016, representando 61,54% do total de medalhas ganhas por esses atletas. Porém, dessas 32 medalhas de ouro, 28 são do Michael Phelps, o equivalente ao 87,50% desse total.

3.4 Relação entre peso e altura

Algo bastante comum na fase de crescimento de todos os seres vivos é o aumento tanto de peso quanto de altura, podendo variar bastante os dois dependendo de cada indivíduo. Porém, isso nem sempre acontece, havendo uma grande variedade possível de alturas e pesos diferentes para todos. E nas Olimpíadas não é diferente, em muitos esportes, possuir uma certa faixa de peso ou uma altura maior, acaba se tornando uma vantagem.

A fim de tentar compreender melhor essa possível relação, foi feita uma análise descritiva, estudando sua correlação, utilizando das variáveis: “Peso (kg)” (quantitativa contínua) e “Altura (m)” (quantitativa contínua), possuindo seus respectivos significados: peso em quilogramas de cada atleta; altura em metros de cada competidor. Para compreender melhor está análise foi feita a seguinte figura e os seguintes quadros:

Figura 6: Gráfico de dispersão do peso pela altura



Quadro 2: Medidas resumo da Altura

Estatística	Valor
Média	1,78
Desvio Padrão	0,12
Variância	0,01
Mínimo	1,37
1º Quartil	1,70
Mediana	1,78
3º Quartil	1,86
Máximo	2,19

Quadro 3: Medidas resumo do Peso

Estatística	Valor
Média	74,14
Desvio Padrão	16,25
Variância	264,11
Mínimo	28,00
1º Quartil	63,00
Mediana	72,00
3º Quartil	84,00
Máximo	175,00

Como pode ser observado pela **Figura 6**, uma grande parte da amostra analisada possui entre 1,50 e 2,00 metros, e de forma semelhante, os atletas se encontram na faixa de peso entre 50 a 100 quilos, sendo destacada pela área mais densa do gráfico.

Para analisar sua correlação, foi utilizado o coeficiente de correlação de Spearman, o qual obteve um valor de $\rho = 0,832$, demonstrando que a relação é forte e positiva entre o peso e a altura das pessoas, o qual mostra que as duas variáveis são diretamente proporcionais, ou seja, quanto maior a altura de um indivíduo, maior tende a ser sua altura.

Como pode ser observado pelos quadros acima, a altura não apresenta uma grande variação com somente 0,12 de desvio padrão. Contudo, o peso existe uma grande variabilidade o qual possui 16,25 de desvio padrão mostrando que apesar de os competidores não haveram muita diferença quando se trata da altura, o peso muda consideravelmente, também sendo evidenciado pela sua diferença de 147 quilogramas entre o indivíduo mais pesado e o mais leve.

4 Conclusões